




Minería de Datos

Tema de la sesión: Clustering

Carrera: Big Data y Ciencia de Datos C28

Capacidades Terminales

Hace uso de modelos no supervisados para la agrupación de observaciones.

Contenido

- Análisis de conglomerados

Motivación

Aplicación de Técnicas de Análisis de Conglomerados y Redes Neuronales Artificiales en la Evaluación del Potencial Exportador de una Empresa

Efraín De La Hoz^{(1)*} y Ludys López Polo⁽²⁾

(1) Universidad de Cartagena, Facultad de Ciencias Económicas, Programa Administración Industrial. Campus Piedra de Bolívar, Cartagena. Colombia, (e-mail: edelahozg@unicartagena.edu.co).

(2) Universidad Simón Bolívar, Facultad de Ingeniería, Programa Ingeniería Industrial. Calle 59 No. 59-81, Barranquilla. Colombia, (e-mail: lulopez@unisimonbolivar.edu.co).

Recibido Mar. 15, 2017; Aceptado May. 10, 2017; Versión final Jun. 15, 2017, Publicado Ago. 2017

Resumen


Se presenta una metodología para el análisis de las condiciones competitivas en el comercio exterior de organizaciones empresariales. El análisis abarca las etapas de medición, evaluación y clasificación de las empresas, a partir de la propuesta de 16 factores clave del potencial exportador. También se evalúa la aplicación del análisis de conglomerados para identificar y caracterizar perfiles competitivos y de redes neuronales artificiales para clasificar el potencial exportador. Los resultados muestran la capacidad del análisis de conglomerados y de las redes neuronales artificiales para discriminar niveles competitivos en el potencial exportador. Su aplicación en el sector químico permitió agrupar las empresas en cuatro perfiles competitivos que asocian sus características. Las redes neuronales artificiales mostraron un 85,7% de capacidad para discriminar y clasificar las empresas según su perfil competitivo.

Palabras clave: potencial exportador; orientación exportadora; competitividad

Revisa el documento PDF en los materiales de la semana 10

Análisis de conglomerados


Conocido también como **análisis de grupos**, **análisis clúster** o simplemente **clustering**, es una técnica estadística multivariante que busca agrupar **elementos (o variables)** tratando de lograr la máxima **homogeneidad** en cada grupo y la mayor diferencia entre los grupos. No tiene bases estadísticas sobre las que deducir inferencias estadísticas para una población a partir de una muestra, ya que es un **método basado en criterios geométricos** y se utiliza fundamentalmente como una **técnica exploratoria, descriptiva** mas no explicativa.



Requisitos para *clustering*

Los requisitos más importantes para utilizar el clustering como herramienta de minería de datos son:

- Escalamiento de los datos
- Capacidad para tratar con diferentes tipos de atributos
- Descubrimiento de clústeres con forma arbitraria
- Requisitos de conocimiento del área para determinar los parámetros de entrada
- Capacidad para tratar con datos ruidosos
- Incremento de clústeres e insensibilidad al orden de entrada
- Capacidad de agrupar datos de dimensión grande
- Interpretabilidad y usabilidad



Medidas de distancia para observaciones

Distancia	Fórmula
Euclídea	$d(x_i, x_j) = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2}$
Minkowski	$d(x_i, x_j) = \left(\sum_{k=1}^n x_{ik} - x_{jk} ^p \right)^{1/p}, p \geq 1$
Manhattan	$d(x_i, x_j) = \sum_{k=1}^n x_{ik} - x_{jk} $
Mahalanobis	$d(x_i, x_j) = \sqrt{(x_i - x_j)' S^{-1} (x_i - x_j)}$

Medidas de distancia para variables numéricas

Coeficiente	Fórmula
De congruencia	$c_{ij} = \frac{\sum_{k=1}^p x_{ik} x_{jk}}{\sqrt{\sum_{k=1}^p x_{ik}^2} \cdot \sqrt{\sum_{k=1}^p x_{jk}^2}}$
De correlación	$r_{ij} = \frac{\sum_{k=1}^p (x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)}{\sqrt{\sum_{k=1}^p (x_{ik} - \bar{x}_i)^2} \cdot \sqrt{\sum_{k=1}^p (x_{jk} - \bar{x}_j)^2}}$

Medidas de asociación para variables dicotómicas

Coeficiente	Fórmula
Simple matching	$SM = \frac{a + d}{a + b + c + d}$
Russell y Rao	$RR = \frac{a}{a + b + c + d}$
Jaccard	$J = \frac{a}{a + b + c}$
Dice-Sørensen	$DS = \frac{2a}{2a + b + c}$

		UEA	
		1	0
UEB	1	1, 1 <i>a</i>	1, 0 <i>b</i>
	0	0, 1 <i>c</i>	0, 0 <i>d</i>

Métodos de análisis de grupos




Métodos jerárquicos

Tienen por objetivo **agrupar clústeres para formar uno nuevo** o bien **separar alguno ya existente para dar origen a otros dos**, de tal forma que, si sucesivamente se va efectuando este proceso de aglomeración o división, se **minimice alguna distancia** o bien se **maximice alguna medida de similitud**.

La forma general de operar de estos métodos es bastante simple. Por ejemplo, en los **métodos aglomerativos** se parte de tantos grupos como individuos haya, luego se selecciona una medida de similitud, agrupándose los dos grupos o clústeres con mayor similitud y se continúa hasta que:


1. Se forma **un solo grupo**.
2. Se alcanza el **número de grupos prefijado**.
3. Se detecta que **hay razones estadísticas** para no continuar agrupando clústeres.



¿Qué es un dendrograma?

Los métodos jerárquicos permiten la construcción de un **árbol de clasificación**, que recibe el nombre de **dendrograma**, en el cual se puede seguir de forma grafica el procedimiento de unión seguido, mostrando qué grupos se van uniendo, en qué nivel concreto lo hacen, así como el valor de la **medida de asociación entre los grupos** cuando estos se agrupan (**nivel de fusión**).

La **interpretación de un dendrograma** es una operación sencilla de realizar. En primer lugar se reconocen visualmente los grandes grupos, es decir, los que se han originado a **bajos niveles de similitud**. Luego, se analizan dichos grupos separándolos en subgrupos hasta llegar a los grupos que presentan la **máxima similitud** entre las observaciones.



Métodos aglomerativos

Método	Definición
Vecino más cercano	Utiliza un algoritmo para agrupar los datos. Busca la distancia mínima entre los individuos más cercanos . Es muy sensible a los datos que puedan provocar el llamado ruido.
Vecino más lejano	Similar al método anterior.
Promedio entre grupos	Calcula la media de la distancia entre los individuos de un grupo y uno de ellos en concreto. Es muy útil para reducir el llamado ruido .
Ward	Suma los cuadrados de las desviaciones entre cada individuo y la media de su clúster, para evitar la pérdida de información . Es uno de los más conocidos y tiene las ventajas del método basado en la media, pero con mayor poder de discriminación .

Métodos disociativos


Método	Definición
Vecino más cercano	Similar al caso anterior, pero usando el método disociativo , es decir, esta vez se separa y no se agrupa.
Vecino más lejano	Similar al caso anterior, pero usando el método disociativo , es decir, esta vez se separa y no se agrupa.
Promedio entre grupos	Similar al caso anterior, pero usando el método disociativo , es decir, esta vez se separa y no se agrupa.
Centroide	En estos este, la semejanza entre dos clústeres viene dada por la semejanza entre sus centroides , esto es, los vectores de medias de las variables medidas sobre los individuos del clúster. Este a su vez se divide en dos: centroide ponderado y centroide no ponderado .

Métodos no jerárquicos

Estos métodos están diseñados para **clasificar individuos** (no son válidos para variables) en una clasificación de **k clústeres**, donde **k se especifica a priori** o bien se determina como una parte del proceso. La idea central de la mayoría de estos procedimientos **es elegir alguna partición inicial de individuos** y después intercambiar los miembros de estos clústeres para obtener una **partición mejor**.

En general, la mayoría de estos métodos constan de tres etapas:


1. Determinar los **centroides** iniciales de los k grupos
2. Formar los **grupos**
3. **Recalcular** los centroides y formar grupos hasta lograr la estabilidad



¿Cómo determinar el número óptimo de clústeres?


Con frecuencia, cuando se emplean **técnicas jerárquicas**, el investigador no está interesado en la jerarquía completa sino en un subconjunto de particiones obtenidas a partir de ella. Las particiones se obtienen cortando el **dendrograma** o seleccionando una de las soluciones en la sucesión encajada de clústeres que comprende la jerarquía. Desafortunadamente este paso fundamental está entre los problemas que todavía no están totalmente resueltos.

Uno de los métodos más utilizados para este fin es el **método del “codo”** el cual analiza la **variación intragrupo** como función de la cantidad de grupos: el **número óptimo de grupos** es aquel que, al ir subdividiendo los grupos, los subgrupos resultantes **no disminuyen de manera significativa la variación intragrupo**.



Medidas de evaluación de *clustering*

Es importante evaluar el resultado de los algoritmos de *clustering*, sin embargo, es difícil definir cuándo el resultado de un agrupamiento es aceptable. Por esta razón existen técnicas e **índices para la validación de un agrupamiento** realizado. Usamos **medidas de evaluación interna** cuando las **etiquetas verdaderas no son conocidas de antemano**, siendo su desventaja la falta de objetividad ya que no estamos comparando con nada que sea verdadero. Por otra parte, usamos **medidas de evaluación externa** cuando **obtenemos etiquetas naturales definidas como ciertas** (por ejemplo, tipo de película) aunque en muchos casos no queremos clústeres predefinidos sino que la separación que se ajuste mejor a la estructura interna de los datos.



Medidas de evaluación interna

Dentro de las más importantes tenemos:

1. **Suma de cuadrados dentro de los clústers (SSW):** Utilizada para evaluar la cohesión de los clústeres.

$$SSW = \sum_{i=1}^k \sum_{x \in C_i} (x - \mu_i)^2$$

2. **Índice Davies-Bouldin (DB):** Valores pequeños para este índice indican clústeres compactos, y cuyos centros están bien separados los unos de los otros.

$$DB = \frac{1}{k} \sum_{i=1, i \neq j}^k \max \left(\frac{\sigma_i + \sigma_j}{d(c_i, c_j)} \right)$$

3. **Índice de Silhouette:** Este índice toma valores entre -1 y 1 , donde -1 indica un mal agrupamiento, 0 es indiferente y 1 indica un buen agrupamiento.

$$S_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

4. **Índice de Calinski-Harabasz (CH):** Cuantifica la relación entre la dispersión dentro de los clústers y la dispersión entre los clústers. Se selecciona el número de clústers que maximiza este índice.

$$CH = \frac{\frac{SSB}{k-1}}{\frac{SSW}{n-1}}$$

Medidas de evaluación externa

Dentro de las más importantes tenemos:

1. **Suma de cuadrados entre los clústers (SSB):** Utilizada para evaluar la distancia interclúster (separación).

$$SSB = \sum_{i=1}^k \sum_{x \in C_i} (x - c_i)^2$$

2. **Índice de Rand (RI):** Compara la similitud de resultados entre dos métodos de agrupación diferentes. Este toma valores entre 0 y 1, donde 0 indica que dos métodos de agrupación en clúster no coinciden en la agrupación de ningún par de elementos y 1 indica que dos métodos de agrupación concuerdan perfectamente en la agrupación de cada par de elementos.

$$RI = \frac{a + b}{C_2^n}$$

3. **Índice de Rand ajustado (ARI):** Versión modificada del anterior que surge debido a que la asignación de clústeres aleatorios no garantiza que $RI = 0$. Este índice toma valores entre -1 y 1 .

4. **Medida V (V_β):** Se define con los conceptos de homogeneidad (h) y completitud (c) similares a la precisión y sensibilidad ya vistos anteriormente. Se calcula como la media armónica entre ambos y maneja un parámetro β . Toma valores entre 0 y 1, y mientras más grande, es mucho mejor.

$$V_\beta = \frac{1 + \beta}{\frac{1}{h} + \frac{\beta}{c}}$$


Comparación entre métodos jerárquicos y no jerárquicos

Jerárquicos	No jerárquicos
No exigen una definición previa del número de clústeres.	Exigen definir previamente el número de clústeres.
Llevan a cabo un proceso iterativo , de abajo hacia arriba con $(n - 1)$ pasos, partiendo de n grupos para terminar en 1 (aglomerativos).	Poseen algunos índices que indican el número óptimo de clústeres .
Permiten obtener distintos tipos de resultados gráficos y numéricos que facilitan la interpretación de los resultados.	Proporcionan los valores de los centroides de los grupos , lo que facilita la interpretación.
Precisan una gran cantidad de cálculos , que en ocasiones limita la posibilidad de aplicación con muestras muy grandes.	Ofrecen resultados adicionales que permiten seleccionar las variables para la interpretación de los clústeres.
Pueden aplicarse sobre las observaciones y sobre las variables .	Solo pueden aplicarse sobre observaciones lográndose soluciones óptimas.

Ejemplos y/o actividades para afianzar lo aprendido


- Con base a una tabla con observaciones, realice lo siguiente:
 - ✓ Halle la matriz de distancias para cada iteración.
 - ✓ Halle los centroides de los nuevos clústers y actualizar la matriz de datos para cada iteración.
 - ✓ Repita el proceso hasta que solamente queden dos clústers.

Utilice el formato que se encuentra en el apartado de Tareas de Canvas.



Conclusiones

- Se definió el análisis de conglomerados, los requisitos para poder aplicarlo y las medidas de similaridad. Además, se mostraron los métodos más importantes para este tipo de análisis: jerárquicos y no jerárquicos.
- Se explicaron las medidas de validación para análisis de grupos existiendo dos tipos: medidas de validación interna y medidas de validación externa.



Referencias Bibliográficas

- Berry, M. & Linoff, G. (2004). *Data Mining Techniques* (2.^a edición). USA. Wiley Publishing, Inc.
- Han, J.; Kamber, M. & Pei, J. (2001). *Data Mining: Concepts and Techniques* (3.^a edición). USA. Elsevier, Inc.
- Hernández, J.; Ramírez, J. & Ferri, C. (2004). *Introducción a la minería de datos*. España. Pearson Educación, S. A.



TECNOLOGÍA
CON SENTIDO